

BỘ GIÁO DỤC VÀ ĐÀO TẠO • HỆ THỐNG ĐÀO TẠO CÔNG NGHỆ THÔNG TIN

KHOA CÔNG NGHỆ THÔNG TIN & TRÍ TUỆ NHÂN TẠO

BÁO CÁO NGHIÊN CỨU & PHÁT TRIỂN HỆ THỐNG AI

BOOMERANG RADAR AI

HỆ THỐNG TRÍ TUỆ NHÂN TẠO DỰ ĐOÁN KHẢ NĂNG KHÁCH HÀNG QUAY LẠI VÀ NHẬN DIỆN SỚM NGUY CƠ RỜI BỎ TRÊN NỀN TẢNG DỮ LIỆU RFM+ MỞ RỘNG

94.23%

ĐỘ CHÍNH XÁC
(ACCURACY)

96.56%

F1-SCORE

96.95%

CHỈ SỐ ROC-AUC

550

CÂY BOOSTING TỐI ƯU

Đề tài nghiên cứu:

Dự đoán Khả năng Khách hàng Quay lại Mua sắm
(Customer Repurchase & Churn Prediction)

Lĩnh vực chuyên môn:

Học máy ứng dụng (Applied Machine Learning), Khoa học Dữ liệu (Data Science)

Thuật toán chủ đạo:

Gradient Boosting Classifier, Random Forest, Decision Tree, Logistic Regression

Nền tảng triển khai:

Python 3.10, Scikit-learn, Flask REST API, Bootstrap 5 Responsive Dashboard

Thời gian thực hiện:

Năm học 2025 - 2026

TÓM TẮT ĐỀ TÀI (ABSTRACT)

Tiếng Việt: Trong bối cảnh bùng nổ của thương mại điện tử và bán lẻ đa kênh, bài toán duy trì lòng trung thành của khách hàng và tối ưu hóa giá trị trọn đời (Customer Lifetime Value - CLV) đã trở thành trọng tâm chiến lược sống còn của mọi doanh nghiệp. Chi phí thu hút một khách hàng mới (CAC) hiện nay đắt gấp 5 đến 7 lần so với chi phí giữ chân một khách hàng hiện hữu. Tuy nhiên, phần lớn các doanh nghiệp bán lẻ vẫn đang tiếp cận bài toán chăm sóc khách hàng một cách thụ động, chỉ can thiệp khi khách hàng đã ngừng phát sinh giao dịch trong một thời gian dài, dẫn đến hiệu quả cứu vãn thấp và chi phí tiếp thị bị lãng phí nghiêm trọng.

Báo cáo này trình bày quá trình nghiên cứu, thiết kế và phát triển toàn diện hệ thống **Boomerang Radar AI** – một giải pháp Trí tuệ Nhân tạo thông minh hoạt động như trạm radar liên tục quét và giám sát dữ liệu hành vi của người tiêu dùng. Hệ thống tích hợp bộ chỉ số hành vi mở rộng RFM+ (Recency, Frequency, Monetary kết hợp Nhân khẩu học và Điểm hài lòng trải nghiệm), tự động sinh 4 biến tương tác phi tuyến (Interaction Features) giúp khai phá sâu sắc nhịp độ tiêu dùng và mức độ gắn kết của khách hàng. Trên cơ sở đó, 4 thuật toán Học máy đại diện (Logistic Regression, Decision Tree, Random Forest, Gradient Boosting) được xây dựng, huấn luyện và tối ưu hóa siêu tham số thông qua kỹ thuật Stratified 5-Fold Cross-Validation và RandomizedSearchCV. Kết quả thực nghiệm trên tập kiểm thử độc lập gồm 1.126 khách hàng chứng minh mô hình **Gradient Boosting Classifier** đạt hiệu năng vượt bậc với độ chính xác **94.23%**, F_1 -score đạt **96.56%** và chỉ số ROC-AUC đạt **96.95%**. Hệ thống được đóng gói hoàn chỉnh dưới dạng Web Application với kiến trúc REST API độ trễ cực thấp (< 50ms), hỗ trợ dự đoán thời gian thực cho từng khách hàng đơn lẻ, xử lý hàng loạt theo tệp CSV, cung cấp cơ chế phân loại rủi ro 4 cấp độ, tự động sinh phân tích hành vi tự nhiên và đề xuất kịch bản can thiệp kịp thời nhằm tạo ra "hiệu ứng Boomerang" kéo khách hàng quay trở lại.

Từ khóa: Khách hàng quay lại (Customer Repurchase), Rời bỏ khách hàng (Customer Churn), Gradient Boosting, RFM Analysis, Kỹ thuật đặc trưng (Feature Engineering), Trí tuệ Nhân tạo trong Thương mại điện tử.

English Abstract: In modern retail and e-commerce ecosystems, customer retention and Customer Lifetime Value (CLV) optimization have emerged as core competitive advantages. Acquiring a new customer (CAC) is five to seven times more costly than retaining an existing one. Nevertheless, traditional Customer Relationship Management (CRM) workflows remain

reactive, identifying churned clients only after prolonged inactivity. This paper introduces **Boomerang Radar AI**, a comprehensive end-to-end Machine Learning system designed to predict customer repurchase probability and deliver early churn warnings. Leveraging engineered RFM+ attributes alongside non-linear interaction features, the pipeline benchmarked Logistic Regression, Decision Trees, Random Forests, and Gradient Boosting algorithms under Stratified 5-Fold Cross-Validation and Randomized Hyperparameter Optimization. Experimental evaluations on a strictly isolated holdout test set of 1,126 customer records demonstrate that the **Gradient Boosting Classifier** outperforms competing baselines, achieving an accuracy of **94.23%**, an F_1 -score of **96.56%**, and an area under the ROC curve (ROC-AUC) of **96.95%**. The production-ready system is delivered as an interactive Flask-based Web Dashboard and low-latency REST API, featuring real-time single-customer inference, batch CSV ingestion, 4-tier churn risk stratification, automated natural-language behavioral synthesis, and actionable omnichannel marketing interventions.

MỤC LỤC BÁO CÁO

Nội dung chương mục	Trang
LỜI NÓI ĐẦU & TÓM TẮT ĐỀ TÀI (ABSTRACT)	ii
DANH MỤC CÁC TỪ VIẾT TẮT & THUẬT NGỮ CHUYÊN MÔN	iv
DANH MỤC BẢNG BIỂU & HÌNH VẼ	v
CHƯƠNG 1: PHÁT BIỂU BÀI TOÁN & CƠ SỞ LÝ THUYẾT	1
1.1. Bối cảnh ngành kinh doanh Bán lẻ và Thương mại điện tử	1
1.2. Lý thuyết Vòng đời Khách hàng (Customer Lifecycle) và Chỉ số LTV	2
1.3. Bản chất toán học của bài toán Phân loại Khách hàng Quay lại	3
1.4. Ý nghĩa thực tiễn và Sứ mệnh của giải pháp Boomerang Radar AI	4
CHƯƠNG 2: XÁC ĐỊNH YÊU CẦU HỆ THỐNG, INPUT VÀ OUTPUT	5
2.1. Yêu cầu chức năng và phi chức năng	5
2.2. Đặc tả chi tiết các thuộc tính đầu vào (Input Specification)	6
2.3. Đặc tả cấu trúc dữ liệu đầu ra và logic phân tầng rủi ro (Output)	7
CHƯƠNG 3: THIẾT KẾ SƠ ĐỒ KHỐI VÀ KIẾN TRÚC HỆ THỐNG	9
3.1. Kiến trúc phân tầng tổng thể (6-Layer Architecture)	9
3.2. Thiết kế luồng dữ liệu (Data Pipeline & Inference Flow)	11
3.3. Cơ chế phân tách module và đóng gói Artifacts	12
CHƯƠNG 4: MÔ TẢ THUẬT TOÁN & CƠ SỞ TOÁN HỌC	13
4.1. Cơ sở toán học của 4 đặc trưng tương tác phi tuyến (Interaction Features)	13
4.2. Thuật toán Hồi quy Logistic (Logistic Regression)	15
4.3. Thuật toán Cây quyết định (Decision Tree Classifier)	16
4.4. Thuật toán Rừng ngẫu nhiên (Random Forest Classifier)	17

4.5. Thuật toán Gradient Boosting Classifier (Champion Model)	18
4.6. Phương pháp tối ưu siêu tham số và Đánh giá chéo phân tầng (Stratified CV)	20
CHƯƠNG 5: MÔ TẢ DỮ LIỆU & QUY TRÌNH TIỀN XỬ LÝ CHỐNG RÒ RỈ	21
5.1. Nguồn gốc dữ liệu và Phân tích khám phá (EDA)	21
5.2. Vấn đề mất cân bằng mẫu và giải pháp xử lý phân tầng	22
5.3. Quy trình tiền xử lý dữ liệu chuẩn hóa chống Data Leakage	23
CHƯƠNG 6: CÀI ĐẶT HỆ THỐNG VÀ XÂY DỰNG ỨNG DỤNG	24
6.1. Môi trường công nghệ và Cấu trúc mã nguồn	24
6.2. Cài đặt chi tiết các Module nghiệp vụ (Data, Train, Predict)	25
6.3. Xây dựng dịch vụ Web REST API và Giao diện Dashboard	26
CHƯƠNG 7: ĐÁNH GIÁ KẾT QUẢ THỰC NGHIỆM	27
7.1. Bảng so sánh tổng hợp hiệu năng giữa các mô hình	27
7.2. Phân tích chi tiết Ma trận nhầm lẫn (Confusion Matrix)	28
7.3. Xếp hạng và Đánh giá độ quan trọng của đặc trưng (Feature Importance)	29
CHƯƠNG 8: HƯỚNG PHÁT TRIỂN & KẾT LUẬN	30
8.1. Ứng dụng Trí tuệ Nhân tạo có thể giải thích (Explainable AI - XAI)	30
8.2. Mở rộng kiến trúc thuật toán chuyên biệt cho dữ liệu bảng	31
8.3. Thiết kế hệ thống MLOps và Tự động hóa tiếp thị đa kênh	31
TÀI LIỆU THAM KHẢO (REFERENCES)	32

CHƯƠNG 1: PHÁT BIỂU BÀI TOÁN & CƠ SỞ LÝ THUYẾT

1.1. Bối cảnh ngành kinh doanh Bán lẻ và Thương mại điện tử (E-Commerce)

Trong thập kỷ qua, sự bùng nổ của công nghệ thông tin và mạng Internet đã thúc đẩy sự chuyển dịch mạnh mẽ từ mô hình bán lẻ truyền thống (Brick-and-Mortar) sang thương mại điện tử (E-Commerce) và bán lẻ đa kênh (Omnichannel Retail). Người tiêu dùng hiện đại đứng trước vô số lựa chọn với rào cản chuyển đổi (Switching Costs) giữa các nhà cung cấp gần như bằng không. Chỉ bằng một cú nhấp chuột hoặc một thao tác lướt trên điện thoại thông minh, khách hàng hoàn toàn có thể tìm thấy một sản phẩm thay thế tương đương từ đối thủ cạnh tranh với mức giá hấp dẫn hơn hoặc chính sách giao hàng nhanh hơn.

Hệ quả tất yếu của môi trường cạnh tranh khốc liệt này là **Chi phí thu hút khách hàng mới (Customer Acquisition Cost - CAC)** trên các kênh truyền thông số (như Google Ads, Facebook Ads, TikTok Ads) liên tục tăng phi mã từ 40% đến 60% mỗi năm. Các doanh nghiệp nhận ra rằng chiến lược "đốt tiền" chạy quảng cáo để tìm kiếm khách hàng mới một lần rồi bỏ mặc họ là một mô hình kinh doanh thiếu bền vững. Lợi nhuận tích lũy thực sự của doanh nghiệp chỉ có thể đạt được khi khách hàng thực hiện các giao dịch lặp lại (Repeat Purchases), gia tăng tần suất mua sắm và duy trì mối quan hệ lâu dài với thương hiệu.

1.2. Lý thuyết Vòng đời Khách hàng (Customer Lifecycle) và Giá trị Trọn đời (CLV)

Theo lý thuyết quản trị quan hệ khách hàng hiện đại, vòng đời của một khách hàng (Customer Lifecycle) trải qua 5 giai đoạn cốt lõi: *Nhận biết (Awareness) → Tiếp cận & Mua lần đầu (Acquisition) → Phát triển gắn kết (Onboarding & Nurturing) → Duy trì lòng trung thành (Retention) → Suy thoái và Rời bỏ (Attrition / Churn)*.

Trọng tâm kinh tế của vòng đời này được định lượng qua chỉ số **Giá trị trọn đời của khách hàng (Customer Lifetime Value - CLV hoặc LTV)**. Về mặt giải tích tài chính, LTV của một khách hàng trong khoảng thời gian $ST\$$ với tỷ lệ chiết khấu $\$d\$$ được biểu diễn qua công thức tổng quát:

$$CLV = \sum_{t=0}^T [(p_t - c_t) \times r_t] / (1 + d)^t$$

Trong đó:

- p_t : Tổng doanh thu kỳ vọng thu được từ khách hàng tại chu kỳ thời gian t .
- c_t : Chi phí trực tiếp phục vụ và chăm sóc khách hàng tại chu kỳ t .
- r_t : Xác suất khách hàng tiếp tục duy trì tương tác và quay lại mua hàng tại chu kỳ t (Retention Rate).
- d : Tỷ lệ chiết khấu tiền tệ theo thời gian.

Công thức trên chứng minh rõ nét: **Xác suất khách hàng quay lại (r_t) là biến số nhân tử quyết định trực tiếp độ lớn của CLV**. Nếu $r_t \rightarrow 0$ (khách hàng rời bỏ sớm), toàn bộ dòng tiền kỳ vọng trong tương lai sẽ bị triệt tiêu, khiến tổng doanh thu không đủ bù đắp chi phí CAC ban đầu. Ngược lại, nghiên cứu kinh điển của *Frederick Reichheld* tại *Bain & Company* đã chỉ ra rằng: việc nâng cao tỷ lệ giữ chân khách hàng thêm **5%** có thể làm tăng lợi nhuận doanh nghiệp từ **25% đến 95%**, bởi vì chi phí vận hành cho khách hàng trung thành thấp hơn rất nhiều và họ sẵn sàng chi tiêu cho những đơn hàng có giá trị cao hơn.

1.3. Bản chất toán học của bài toán Phân loại Khách hàng Quay lại

Để giải quyết bài toán dự đoán hành vi của người tiêu dùng, chúng tôi mô hình hóa bài toán dưới góc nhìn **Học máy có giám sát (Supervised Machine Learning)** theo bài toán **Phân loại nhị phân (Binary Classification)**.

Giả sử không gian mẫu $\mathcal{X} \subseteq \mathbb{R}^d$ biểu diễn vector đặc trưng đa chiều của khách hàng, bao gồm lịch sử giao dịch RFM, đặc điểm nhân khẩu học và các thông tin phản hồi trải nghiệm dịch vụ:

$$\mathbf{x}_i = [x_{i1}, x_{i2}, \dots, x_{id}]^T \in \mathcal{X}$$

Không gian nhãn $\mathcal{Y} = \{0, 1\}$ thể hiện trạng thái phát sinh đơn hàng của khách hàng trong khoảng thời gian quan sát tiếp theo:

- $y_i = 1$: Khách hàng **sẽ quay lại mua sắm** (Repurchase / Retained).
- $y_i = 0$: Khách hàng **không quay lại / rời bỏ dịch vụ** (Churn / At-Risk).

Mục tiêu của thuật toán học máy là tìm kiếm một hàm giả thuyết (Hypothesis function) $f: \mathcal{X} \rightarrow [0, 1]$ xấp xỉ phân phối xác suất hậu nghiệm thực tế:

$$f(\mathbf{x}_i) = P(y_i = 1 \mid \mathbf{x}_i)$$

Sau khi thu được xác suất $P(y_i = 1 \mid \mathbf{x}_i)$, hệ thống áp dụng một ngưỡng quyết định (Decision Threshold) $\theta \in (0, 1)$ (thông thường $\theta = 0.50$) để gán nhãn dự đoán nhị phân $\hat{y}_i$:

$$\hat{y}_i = \begin{cases} 1 & \text{nếu } P(y_i = 1 \mid \mathbf{x}_i) \geq \theta, \\ 0 & \text{nếu } P(y_i = 1 \mid \mathbf{x}_i) < \theta \end{cases}$$

1.4. Ý nghĩa thực tiễn và Sức mạnh của giải pháp Boomerang Radar AI

Trong thực tế vận hành doanh nghiệp, việc dự đoán chính xác xác suất khách hàng quay lại đem lại những giá trị chiến lược mang tính đột phá:

1. Chuyển dịch từ CSKH thụ động sang phòng ngừa chủ động (Proactive Retention):

Hầu hết các hệ thống CRM hiện tại chỉ ghi nhận một khách hàng đã rời bỏ khi họ đã bất hoạt 90 hay 180 ngày. Khi đó, sự quan tâm của khách hàng đã chuyển sang thương hiệu khác. *Boomerang Radar AI* hoạt động như một hệ thống cảnh báo sớm, phát hiện những dấu hiệu rạn nứt đầu tiên (tần suất giảm, ngày chưa mua dài hơn nhịp độ bình thường, điểm hài lòng thấp) để doanh nghiệp can thiệp ngay từ trong "thời điểm vàng".

2. Tối ưu hóa ngân sách Marketing và Khuyến mãi (Voucher Allocation Optimization):

Thay vì phát mã giảm giá đại trà gây lãng phí ngân sách (Discount Cannibalization) và làm giảm giá trị thương hiệu, hệ thống giúp phân loại chính xác:

- *Khách hàng trung thành tự nhiên* ($P > 85\%$): Không cần phát voucher giảm sâu, chỉ cần tặng ưu đãi tích lũy điểm VIP hoặc giới thiệu sản phẩm mới.
- *Khách hàng đứng trước nguy cơ rời bỏ* ($20\% \leq P \leq 50\%$): Cần gửi ngay voucher trợ giá hoặc miễn phí vận chuyển để tái kích hoạt hành vi.
- *Khách hàng Churn hoàn toàn* ($P < 15\%$): Kích hoạt kịch bản gọi điện chăm sóc cá nhân hóa từ trung tâm CSKH.

3. Hiện thực hóa "Hiệu ứng Boomerang":

Giống như nguyên lý khí động học của chiếc boomerang luôn quay trở lại điểm xuất phát sau khi phóng đi, hệ thống Boomerang Radar AI hướng đến việc thiết lập một chu trình tuần hoàn kín trong việc nuôi dưỡng trải nghiệm, biến mỗi giao dịch đơn lẻ thành điểm khởi đầu cho chuỗi giá trị giao dịch bền vững trong tương lai.

CHƯƠNG 2: XÁC ĐỊNH YÊU CẦU HỆ THỐNG, INPUT VÀ OUTPUT

2.1. Phân tích yêu cầu hệ thống

Hệ thống **Boomerang Radar AI** được thiết kế theo các tiêu chuẩn kỹ thuật phần mềm và kiến trúc học máy hướng dịch vụ (Service-Oriented Machine Learning Architecture). Hệ thống phải đáp ứng đầy đủ cả hai nhóm yêu cầu chức năng và phi chức năng nhằm phục vụ song song cho hai nhóm đối tượng: Chuyên viên Marketing/Bán hàng (thao tác trên giao diện trực quan) và Kỹ sư phần mềm/Hệ sinh thái bên ngoài (tích hợp qua API).

2.1.1. Yêu cầu chức năng (Functional Requirements - FR)

- **FR-01: Dự đoán thời gian thực cho một khách hàng đơn lẻ (Real-Time Single Prediction):**

Cung cấp giao diện form web nhập liệu trực quan cho 8 chỉ số hành vi. Sau khi người dùng nhấn nút "Dự đoán", hệ thống chuyển đổi dữ liệu, thực hiện suy luận qua mô hình AI đã huấn luyện và phản hồi kết quả trong thời gian thực dưới 100 mili-giây.

- **FR-02: Dự đoán hàng loạt theo lô từ tệp tin CSV (Batch CSV Prediction):**

Cho phép người dùng tải lên tệp tin định dạng .csv chứa từ vài trăm đến hàng chục nghìn bản ghi khách hàng. Hệ thống tự động kiểm tra tính hợp lệ của cấu trúc cột, thực hiện xử lý theo lô và trả về bảng kết quả phân loại kèm tính năng xuất tệp **Export CSV** đã bổ sung cột nhãn và xác suất.

- **FR-03: Khảo sát và đối chuẩn mô hình (Model Benchmarking Dashboard):**

Cung cấp bảng so sánh chi tiết giữa 4 mô hình học máy theo các chỉ số: *Accuracy*, *Precision*, *Recall*, *F1-Score*, *ROC-AUC*. Hiển thị trực quan Ma trận nhầm lẫn (Confusion Matrix) dạng lưới và biểu đồ xếp hạng độ quan trọng của các đặc trưng (Feature Importance).

- **FR-04: Thống kê và khám phá dữ liệu (Data Overview & Analytics):**

Tự động nạp và thống kê các chỉ số kinh doanh vĩ mô từ tệp dữ liệu sạch: tổng số lượng khách hàng, tỷ lệ khách quay lại thực tế, tỷ lệ rời bỏ, giá trị đơn hàng trung bình toàn hệ thống và bảng xem trước (preview) dữ liệu mẫu.

- **FR-05: Tự động phân tầng mức độ rủi ro (Risk Stratification Engine):**

Căn cứ vào xác suất quay lại tính toán được, hệ thống tự động phân loại khách hàng vào 4 phân khúc rủi ro: *Rất Thấp*, *Trung Bình*, *Cao*, *Rất Cao* (Nguy cơ Churn).

- **FR-06: Sinh phân tích hành vi và đề xuất hành động nghiệp vụ (Synthesis & Actionable Recommendation):**

Dựa trên sự kết hợp giữa 8 thuộc tính RFM+ và cấp độ rủi ro, hệ thống tự động sinh câu văn giải thích ngắn gọn hành vi mua sắm và đưa ra kịch bản Marketing/CSKH cụ thể cho nhân viên kinh doanh.

2.1.2. Yêu cầu phi chức năng (Non-Functional Requirements - NFR)

- **NFR-01: Tiêu chuẩn độ chính xác cao (High Accuracy & Balance):**

Do đặc thù dữ liệu phân loại nhị phân thực tế có tính mất cân bằng tự nhiên (Imbalanced Dataset), hệ thống đặt mục tiêu tối thượng vào việc tối ưu chỉ số $F_1\text{-score} \geq 92\%$, đồng thời đảm bảo $\text{Accuracy} \geq 90\%$ và chỉ số $\text{ROC-AUC} \geq 0.90$ trên tập kiểm thử độc lập (Held-out Test Set).

- **NFR-02: Độ trễ phản hồi cực thấp (Low Latency):**

Bộ máy suy luận (Inference Engine) phải tối ưu hóa cấu trúc nạp mô hình vào bộ nhớ RAM (Lazy-loaded singleton model artifact), đảm bảo thời gian xử lý một yêu cầu qua REST API $\leq 50\text{ms}$.

- **NFR-03: Bảo toàn tính phân bố và chống rò rỉ dữ liệu (Anti-Data Leakage Protocol):**

Quy trình tiền xử lý phải cô lập hoàn toàn giữa tập huấn luyện và tập kiểm thử. Bộ chuẩn hóa (Scaler) và bộ mã hóa (Encoder) chỉ được phép học các tham số thống kê (μ, σ) trên tập Train để đảm bảo mô hình không bị "học vẹt" trước các phân phối của tập Test.

- **NFR-04: Tính mở rộng và khả năng tích hợp (Extensibility & Portability):**

Kiến trúc mã nguồn được phân rã thành các module độc lập (Data Processing, Training, Inference, API Web). Toàn bộ mô hình và bộ biến đổi được lưu trữ dưới dạng nhị phân .joblib, cho phép dễ dàng container hóa qua Docker hoặc tích hợp vào hệ thống ERP/CRM của doanh nghiệp.

- **NFR-05: Trải nghiệm người dùng (UX/UI Responsiveness):**

Giao diện Web Dashboard được xây dựng trên nền tảng Bootstrap 5 tương thích trên cả trình duyệt máy tính để bàn (Desktop), máy tính bảng và thiết bị di động.

2.2. Đặc tả dữ liệu đầu vào (Input Specification)

Để mô tả toàn diện chân dung khách hàng mà không làm phức tạp hóa quá trình nhập liệu, hệ thống chọn lọc **8 đặc trưng cốt lõi** thuộc 4 nhóm nghiệp vụ chính: Nhân khẩu học, Hành vi giao

dịch RFM (Recency, Frequency, Monetary), Hành vi khuyến mãi và Phản hồi trải nghiệm dịch vụ.

Tên thuộc tính	Kiểu dữ liệu	Miền giá trị hợp lệ	Phân loại nghiệp vụ	Ý nghĩa kinh doanh & Ràng buộc logic
age	Integer	$\$18 \leq \text{age} \leq 70\$$	Nhân khẩu học	Độ tuổi sinh học của khách hàng. Nhóm khách hàng trẻ thường nhạy cảm với khuyến mãi hơn nhóm trung niên.
gender	Categorical	Nam, Nữ	Nhân khẩu học	Giới tính khách hàng. Dùng để cá nhân hóa danh mục sản phẩm gợi ý khi tái kích hoạt.
total_purchases	Integer	$\$1 \leq \text{total} \leq 60\$$ (đơn)	Tần suất (Frequency)	Tổng số lượng đơn hàng mà khách hàng đã thực hiện thành công kể từ khi đăng ký tài khoản.
avg_order_value	Float	$\$150.000 \leq \text{AOV} \leq 4.500.000\$$ đ	Giá trị tiền tệ (Monetary)	Giá trị trung bình trên mỗi đơn hàng (VNĐ). Phản ánh khả năng chi trả và mức độ giàu có của khách hàng.
days_since_last_purchase	Integer	$\$1 \leq \text{days} \leq 180\$$ (ngày)	Độ mới tương tác (Recency)	Khoảng cách thời gian tính bằng ngày kể từ giao dịch thành công gần nhất. Biến số nhạy cảm nhất đối với nguy cơ rời bỏ.
membership_level	Categorical	Đồng, Bạc, Vàng, Kim Cương	Khách hàng thân thiết	Hạng thẻ tích lũy dựa trên doanh thu. Phản ánh mức độ gắn kết chính sách và quyền

Tên thuộc tính	Kiểu dữ liệu	Miền giá trị hợp lệ	Phân loại nghiệp vụ	Ý nghĩa kinh doanh & Ràng buộc logic
				lợi khách hàng thân thiết.
used_voucher	Binary	\$0\$ (Không), \$1\$ (Có)	Hành vi khuyến mãi	Đo lường sự phụ thuộc vào các chương trình kích cầu giảm giá của khách hàng.
satisfaction_score	Integer	\$1, 2, 3, 4, 5\$ (sao)	Chất lượng dịch vụ (CSAT)	Điểm số đánh giá trải nghiệm mua sắm gần nhất từ các phiếu khảo sát CSAT hoặc đánh giá đơn hàng.

2.3. Đặc tả cấu trúc dữ liệu đầu ra và logic phân tầng rủi ro (Output)

Khi tiếp nhận một bản ghi thông tin khách hàng, hệ thống thực hiện pipeline suy luận và cấu trúc hóa kết quả đầu ra dưới định dạng JSON tiêu chuẩn phục vụ trực tiếp cho giao diện và hệ thống ngoài:

```
{
  "probability_return": 0.9423,
  "probability_return_pct": 94.2,
  "churn_risk_pct": 5.8,
  "prediction_label": 1,
  "label_formatted": "Nhãn 1 (Quay lại)",
  "status_text": "Quay lại mua sắm",
  "threshold_used": 0.50,
  "risk_level": "Rất Thấp",
  "synthesis_analysis": "Tần suất mua cao (12 lần) giá trị đơn lớn (1.850.000 VNĐ) mới mua dưới 30 ngày (14 ngày) điểm hài lòng tốt (5/5).",
  "recommended_action": "Khách hàng rất trung thành. Gửi mã ưu đãi Tri ân VIP 15% & đề xuất bộ sưu tập sản phẩm mới.",
  "model_used": "Gradient Boosting"
}
```

2.3.1. Ma trận phân tầng mức độ rủi ro rời bỏ (Risk Stratification Matrix)

Hệ thống chia xác suất quay lại $P = P(y=1 \mid \mathbf{x})$ thành 4 phân vùng rủi ro:

Cấp độ rủi ro (Risk Tier)	Khoảng xác suất quay lại	Khoảng nguy cơ rời bỏ (Churn)	Đặc điểm hành vi tiêu biểu	Hành động nghiệp vụ đề xuất
1. Rất Thấp (Very Low)	$P > 80\%$	$P_{\text{churn}} < 20\%$	Khách VIP, tần suất mua đều đặn, AOV cao, điểm hài lòng 4 - 5 sao.	Không giảm giá đại trà. Gửi thiệp tri ân, tặng quyền lợi phòng chờ VIP, ưu tiên xem trước bộ sưu tập mới.
2. Trung Bình (Moderate)	$50\% \leq P \leq 80\%$	$20\% \leq P_{\text{churn}} \leq 50\%$	Vẫn có ý định quay lại nhưng khoảng cách ngày mua đang dài ra; có thể chờ khuyến mãi.	Gửi thông báo đẩy (App Push) nhắc nhở sản phẩm đã xem kèm mã giảm giá 10% có thời hạn 48 giờ.
3. Cao (High Risk)	$20\% \leq P < 50\%$	$50\% < P_{\text{churn}} \leq 80\%$	Bắt đầu nguội lạnh tương tác (> 60 ngày chưa mua), điểm hài lòng ở mức trung bình (3 sao).	Cảnh báo nguy cơ! Kích hoạt chiến dịch "We Miss You" qua Zalo/Email kèm Voucher 20% và chính sách miễn phí vận chuyển.
4. Rất Cao (Critical Churn)	$P < 20\%$	$P_{\text{churn}} > 80\%$	Báo động đỏ! Đã quá lâu không mua (> 90 - 120 ngày), đánh giá 1 - 2 sao hoặc mua ít đơn.	Chuyển danh sách cho bộ phận Chăm sóc khách hàng đặc biệt: gọi điện thăm hỏi trải nghiệm lỗi, tặng quà bù đắp và voucher 25%.

CHƯƠNG 3: THIẾT KẾ SƠ ĐỒ KHỐI VÀ KIẾN TRÚC HỆ THỐNG

3.1. Kiến trúc phân tầng tổng thể (6-Layer Architecture)

Để đảm bảo tính độc lập, khả năng kiểm thử từng phần (Unit Testing) và khả năng sẵn sàng triển khai trong môi trường doanh nghiệp thực tế, hệ thống **Boomerang Radar AI** được thiết kế theo **Kiến trúc phân tầng 6 lớp (6-Layer Decoupled Architecture)**. Mỗi tầng chịu trách nhiệm xử lý một nghiệp vụ chuyên biệt và chỉ giao tiếp với các tầng liền kề thông qua các giao diện định nghĩa rõ ràng (Clean Interfaces).

TẦNG 1 TẦNG THU THẬP & NHẬP LIỆU DỮ LIỆU (DATA INGESTION LAYER)**Tập CSV/Excel Gốc**

Nạp dữ liệu lịch sử giao dịch bán lẻ (data/raw/ hoặc customer_repurchase_data.csv)

Web Form Input

Giao diện nhập liệu trực quan 8 chỉ số của một khách hàng trên Dashboard

Batch CSV Ingestion

Nhận tệp tin CSV tải lên chứa danh sách khách hàng cần quét đồng thời

REST API Payload

Tiếp nhận các truy vấn JSON gửi đến từ các dịch vụ Backend/CRM bên ngoài

TẦNG 2 TẦNG TIỀN XỬ LÝ & KỸ THUẬT ĐẶC TRƯNG (PREPROCESSING & FEATURE PIPELINE)**Data Cleaning Engine**

Điền khuyết thiếu bằng trung vị (Median Imputation), chuẩn hóa định dạng số và nhãn

Interaction Engineering

Tính 4 biến phi tuyến: purchase_intensity, ltv_score, satisfaction_recency, voucher_low_value

Stratified Splitting

Chia tách Train/Test 80/20 có phân tầng bảo toàn phân phối nhãn trước khi fit transformer

ColumnTransformer

StandardScaler (10 cột liên tục) + OneHotEncoder (2 cột danh mục drop='first') → 14 chiều

TẦNG 3 TẦNG MÔ HÌNH HÓA & TỐI ƯU HỌC MÁY (MODELING & OPTIMIZATION LAYER)**Logistic Regression**

Baseline tuyến tính, tối ưu C qua GridSearchCV trên không gian tham số logarit

Decision Tree

Cây quyết định phi tuyến, tối ưu max_depth, min_samples_split qua RandomizedSearchCV

Random Forest

Ensemble 550 cây Bagging độc lập, tối ưu số lượng cây và tỷ lệ đặc trưng con

Gradient Boosting

Champion Model! 550 cây Boosting tuần tự, lr=0.0562, depth=14, subsample=0.95

TẦNG 4 TẦNG LƯU TRỮ ARTIFACTS & TÀI NGUYÊN MÔ HÌNH (STORAGE & ARTIFACTS LAYER)**preprocessor.joblib**

Chứa đối tượng ColumnTransformer đã học các tham số, σ từ tập Train

gradient_boosting.joblib

Tập tin nhị phân lưu trữ toàn bộ cấu trúc và trọng số của mô hình vô địch

feature_names.joblib

Danh mục tên 14 đặc trưng sau khi mã hóa one-hot phục vụ mapping Feature Importance

evaluation_results.json

Lưu trữ toàn bộ chỉ số thực nghiệm, ma trận nhầm lẫn và siêu tham số tối ưu

**TẦNG
5****TẦNG DỊCH VỤ & SUY LUẬN THỜI GIAN THỰC (APPLICATION & INFERENCE LAYER)****REST API Gateway**

Flask Router định tuyến các Endpoint:
/api/predict,
/api/predict-batch,
/api/models, /api/stats

Inference Engine

Thực hiện nạp mô hình lười (Lazy-loading), biến đổi vector đặc trưng và tính toán predict_proba()

Synthesis Logic Engine

Engine quy tắc tự động phân tích sâu đa chiều và sinh câu diễn giải ngữ cảnh tự nhiên

Batch Processing Engine

Xử lý song song dữ liệu bảng từ file CSV, định dạng kết quả và xuất tệp tin

**TẦNG
6****TẦNG GIAO DIỆN NGƯỜI DÙNG & TƯƠNG TÁC (PRESENTATION & DASHBOARD LAYER)****Tab 1: Overview**

Thống kê trực quan chỉ số vĩ mô (tỷ lệ rời bỏ, AOV) và bảng xem trước dữ liệu mẫu

Tab 2: Predictor

Form nhập liệu trực quan, Radar quét nguy cơ, thẻ kết quả cảnh báo và đề xuất hành động

Tab 3: Benchmark

Bảng so sánh 4 mô hình, Ma trận nhầm lẫn và biểu đồ Feature Importance bằng Chart.js

Tab 4: Batch

Kéo thả tệp CSV hàng loạt, hiển thị kết quả phân loại phân trang và nút Export CSV

3.2. Thiết kế luồng dữ liệu (Data Pipeline & Inference Flow)

Kiến trúc hệ thống được phân định rạch ròi thành hai chu trình luồng dữ liệu: **Chu trình huấn luyện ngoại tuyến (Offline Training Pipeline)** và **Chu trình suy luận trực tuyến (Online Inference Pipeline)**.

3.2.1. Chu trình huấn luyện ngoại tuyến (Offline Pipeline)

- 1. Thu nạp & Làm sạch (Ingestion & Cleaning):** Tập dữ liệu lịch sử được nạp từ `data/customer_repurchase_data.csv`. Thuật toán Median Imputation được áp dụng để điền các giá trị thiếu ở các trường số, các thuộc tính phân loại được chuẩn hóa về định dạng nhị phân hoặc chuỗi tiếng Việt đồng nhất.
- 2. Đặc trưng hóa tương tác (Interaction Feature Engineering):** Dữ liệu được đưa qua hàm `engineer_features()` để tính toán 4 chỉ số mở rộng.
- 3. Phân chia tập có bảo toàn nhân (Stratified Split):** Toàn bộ bảng dữ liệu được chia theo tỷ lệ 80% cho tập huấn luyện và 20% cho tập kiểm thử bằng hàm `train_test_split(stratify=y)`.
- 4. Đóng băng bộ biến đổi (Fit Preprocessor):** Đối tượng `ColumnTransformer` thực hiện học các tham số chuẩn hóa trên `$X_{\text{train}}$` và biến đổi sang vector 14 chiều. Sau đó,

toàn bộ đối tượng biến đổi được lưu thành `models/preprocessor.joblib`.

5. **Tối ưu hóa và Kiểm định chéo (Tuning & Cross-Validation):** Thực hiện chạy `RandomizedSearchCV` trên không gian tham số của từng thuật toán với 5-Fold Stratified CV.
6. **Đánh giá độc lập và Xuất Artifacts:** Mô hình tối ưu được kiểm tra trên X_{test} . Toàn bộ trọng số mô hình tốt nhất, danh mục đặc trưng và file JSON đánh giá được tuần tự hóa và ghi vào thư mục `models/`.

3.2.2. Chu trình suy luận trực tuyến (Online Inference Pipeline)

1. **Tiếp nhận yêu cầu (Request Ingestion):** Khách hàng nhập thông tin trên form web hoặc gửi một payload JSON đến `POST /api/predict`.
2. **Ánh xạ đặc trưng (Dynamic Feature Engineering):** Dữ liệu đơn lẻ dạng Dictionary được chuyển thành DataFrame 1 dòng và đưa qua cùng hàm `engineer_features()` để sinh 4 biến tương tác phi tuyến giống hệt như lúc huấn luyện.
3. **Biến đổi không rò rỉ (Deterministic Transform):** Đối tượng `preprocessor.joblib` được gọi qua phương thức `.transform()` (tuyệt đối không fit lại), chuyển đổi 1 dòng dữ liệu thô thành vector số học chuẩn 14 chiều.
4. **Ước lượng xác suất (Probability Estimation):** Mô hình `Champion gradient_boosting_model.joblib` thực hiện hàm `predict_proba()` để trích xuất xác suất quay lại $P(y=1 \mid \mathbf{x})$.
5. **Phân tích quy tắc & Sinh khuyến nghị:** Xác suất cùng 8 thuộc tính ban đầu được đưa qua bộ phân tích quy tắc `generate_synthesis_analysis()` để tạo ra câu diễn giải hành vi, mức độ rủi ro và khuyến nghị hành động tương ứng.
6. **Đóng gói phản hồi:** Toàn bộ kết quả được đóng gói thành JSON và phản hồi về client với độ trễ dưới 50ms.

3.3. Cơ chế phân tách module và quản lý trạng thái mô hình

Hệ thống áp dụng cơ chế **Decoupled Architecture**: Mã nguồn huấn luyện (`src/train.py`) và mã nguồn phục vụ suy luận (`src/predict.py`, `app.py`) hoàn toàn độc lập với nhau. Trong môi trường Production, máy chủ web không bao giờ phải chạy lại quá trình huấn luyện tốn kém tài nguyên mà chỉ nạp (load) các file nhị phân tĩnh đã được kiểm định chất lượng nghiêm ngặt. Điều này cho phép mở rộng quy mô hệ thống (Scale-out) theo chiều ngang một cách dễ dàng thông qua việc khởi chạy nhiều instance Flask đằng sau một bộ cân bằng tải (Load Balancer).

CHƯƠNG 4: MÔ TẢ THUẬT TOÁN & CƠ SỞ TOÁN HỌC

Chương này đi sâu vào cơ sở lý thuyết toán học, các phương trình vi tích phân, đại số tuyến tính và cơ chế tối ưu hóa đằng sau toàn bộ quy trình xây dựng đặc trưng và 4 mô hình học máy được triển khai trong hệ thống **Boomerang Radar AI**.

4.1. Cơ sở toán học của 4 đặc trưng tương tác phi tuyến (Interaction Features)

Trong các bài toán dữ liệu bảng (Tabular Data), nếu chỉ đưa các biến thô độc lập vào mô hình, các giải thuật phân loại tuyến tính hoặc cây quyết định có độ sâu nông sẽ rất khó nắm bắt được những mối quan hệ nhân quả tương hỗ phi tuyến giữa các chiều không gian. Dựa trên lý thuyết kinh tế học hành vi và mô hình RFM, chúng tôi thiết kế 4 biến tương tác giải tích:

1. Cường độ mua sắm (Purchase Intensity)

Biến số này đo lường nhịp độ phát sinh giao dịch trên một đơn vị thời gian gần nhất của khách hàng. Công thức giải tích được xác định như sau:

$$\text{purchase_intensity} = \frac{\text{total_purchases}}{\text{days_since_last_purchase} + 1}$$

Phân tích toán học:

Hệ số cộng mẫu số $+1$ đóng vai trò là tham số làm mịn (smoothing parameter), ngăn chặn triệt để lỗi chia cho 0 trong trường hợp khách hàng vừa phát sinh giao dịch trong ngày ($\text{days} = 0$).

Xét đạo hàm riêng theo số ngày chưa mua lại:

$$\frac{\partial (\text{purchase_intensity})}{\partial (\text{days})} = - \frac{\text{total_purchases}}{(\text{days} + 1)^2} < 0 \quad (\text{forall } \text{total} \geq 1, \text{days} \geq 0)$$

Đạo hàm luôn mang dấu âm, phản ánh tính chất giảm đơn điệu phi tuyến theo luật nghịch đảo bình phương: Càng nhiều ngày không mua, cường độ tương tác suy giảm rất nhanh ở giai đoạn đầu và tiệm cận về 0 ở giai đoạn sau.

2. Điểm giá trị vòng đời giảm lược (LTV Score)

Kết hợp trực tiếp giữa tần suất giao dịch lũy kế và giá trị trung bình trên mỗi đơn hàng nhằm ước lượng quy mô tổng đóng góp tài chính của khách hàng cho hệ thống bán lẻ:

$$\text{ltv_score} = \frac{\text{total_purchases}}{\text{avg_order_value}} \times 1.000.000 \quad (\text{đơn vị: triệu VNĐ})$$

Việc chia cho hệ số quy đổi tỷ lệ 10^6 giúp chuẩn hóa thang đo về miền giá trị trực quan từ \$0.15\$ đến hơn \$200\$ triệu đồng, hỗ trợ các thuật toán gradient hội tụ ổn định hơn.

3. Mức độ hài lòng theo hàm suy giảm thời gian (Satisfaction Recency)

Một khách hàng từng đánh giá 5 sao nhưng đã 150 ngày không quay lại có tâm lý hoàn toàn khác với một khách hàng đánh giá 5 sao vừa mua hàng cách đây 7 ngày. Để mô hình hóa hiện tượng "phai nhạt ký ức trải nghiệm" (Memory Decay Effect), chúng tôi xây dựng công thức:

$$\text{satisfaction_recency} = \left(\frac{\text{satisfaction_score}}{\text{days_since_last_purchase} + 1} \right) \times 30$$

Trong đó, thừa số \$30\$ biểu diễn chu kỳ chuẩn hóa 1 tháng. Nếu khách hàng đánh giá 5 sao và mua hàng cách đây 29 ngày ($\text{days} + 1 = 30$), điểm số được chuẩn hóa chính xác bằng \$5.0\$. Nếu số ngày tăng lên 90 ngày, giá trị này sẽ suy giảm chỉ còn \$1.67\$, phản ánh đúng thực tế trải nghiệm tốt trước đây đã mất dần tác dụng giữ chân.

4. Nhận diện nhóm chuyên săn giảm giá giá trị thấp (Voucher Low Value)

Trong bán lẻ, nhóm khách hàng "Voucher Hunters" chỉ mua sắm khi có mã giảm giá và thường chọn những mặt hàng có giá trị thấp nhất để tối đa hóa mức chiết khấu. Nhóm này có mức độ trung thành thương hiệu cực kỳ kém. Đặc trưng nhị phân này được xây dựng thông qua hàm chỉ thị (Indicator Function):

$$\text{voucher_low_value} = \text{used_voucher} \times \mathbb{I}(\text{avg_order_value} \leq 300.000 \text{ VNĐ})$$

Biến nhận giá trị \$1\$ nếu khách hàng vừa thỏa mãn điều kiện có áp dụng voucher vừa có giá trị đơn hàng trung bình dưới 300.000 VNĐ; ngược lại nhận giá trị \$0\$.

4.2. Thuật toán Hồi quy Logistic (Logistic Regression)

Hồi quy Logistic là thuật toán phân loại tuyến tính nền tảng. Thay vì khớp một đường hồi quy trực tiếp, mô hình liên kết tổ hợp tuyến tính của các biến đầu vào với xác suất phân loại thông

qua hàm kích hoạt **Sigmoid (Logistic Function)**:

$$z = \mathbf{w}^T \mathbf{x} + b = w_1 x_1 + w_2 x_2 + \dots + w_d x_d + b$$

$$\sigma(z) = \frac{1}{1 + e^{-z}} \in (0, 1)$$

Xác suất hậu nghiệm có điều kiện được tính như sau:

$$P(y = 1 \mid \mathbf{x}) = \sigma(z) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}}$$

$$P(y = 0 \mid \mathbf{x}) = 1 - P(y = 1 \mid \mathbf{x}) = \frac{e^{-(\mathbf{w}^T \mathbf{x} + b)}}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}}$$

Hàm mất mát và Tối ưu hóa điều chuẩn L_2 (Ridge)

Hàm mục tiêu được xây dựng dựa trên nguyên lý Hợp lý cực đại (Maximum Likelihood Estimation - MLE), tương đương với việc tối thiểu hóa hàm mất mát **Binary Cross-Entropy** có bổ sung số hạng phạt điều chuẩn L_2 :

$$J(\mathbf{w}, b) = -\frac{1}{N} \sum_{i=1}^N \left[y_i \ln(\hat{y}_i) + (1 - y_i) \ln(1 - \hat{y}_i) \right] + \frac{1}{2C} \|\mathbf{w}\|_2^2$$

Trong đó:

- $\hat{y}_i = \sigma(\mathbf{w}^T \mathbf{x}_i + b)$ là xác suất dự đoán của mẫu thứ i .
- $C > 0$ là siêu tham số nghịch đảo của cường độ điều chuẩn (Inverse Regularization Strength). C càng nhỏ thì mức phạt trọng số càng lớn, giúp chống quá khớp (Overfitting).
- Hệ thống thực hiện tối ưu hóa qua thuật toán **L-BFGS (Limited-memory Broyden–Fletcher–Goldfarb–Shanno)** kết hợp GridSearchCV trên miền $C \in \{0.001, 0.01, 0.1, 0.5, 1.0, 5.0, 10.0, 50.0\}$.

4.3. Thuật toán Cây quyết định (Decision Tree Classifier)

Cây quyết định phân chia không gian đặc trưng một cách đệ quy thành các siêu hình hộp chữ nhật đồng nhất thông qua cấu trúc cây phân cấp gồm: Gốc (Root), Các nút điều kiện phân nhánh (Decision Nodes) và Các nút lá (Leaf Nodes) gán nhãn dự đoán.

Tại mỗi bước phân chia tại nút S , thuật toán tìm kiếm đặc trưng A và ngưỡng phân chia θ sao cho độ tinh khiết sau phân tách đạt mức tối đa. Hai tiêu chí đo lường độ hỗn loạn thông tin được thử nghiệm:

1. Entropy và Độ lợi thông tin (Information Gain)

$$H(S) = -\sum_{c \in \{0, 1\}} p_c \log_2(p_c)$$

$$\text{Gain}(S, A) = H(S) - \sum_{v \in \{\text{left}, \text{right}\}} \frac{|S_v|}{|S|} H(S_v)$$

2. Chỉ số vẫn đục Gini (Gini Impurity)

$$I_G(S) = 1 - \sum_{c \in \{0, 1\}} p_c^2 = 1 - (p_0^2 + p_1^2) = 2 p_0 p_1$$

Trong đó p_c là tỷ lệ mẫu thuộc lớp c tại nút S . Thuật toán chọn điểm cắt cực đại hóa $\Delta I_G = I_G(S) - \frac{|S_L|}{|S|} I_G(S_L) - \frac{|S_R|}{|S|} I_G(S_R)$.

Chiến lược kiểm soát quá khớp: Để tránh việc cây phát triển quá sâu ghi nhớ nhiều (Overfitting), hệ thống sử dụng RandomizedSearchCV để không chế: $\text{max_depth} \leq 16$, $\text{min_samples_split} \geq 5$, $\text{min_samples_leaf} \geq 2$.

4.4. Thuật toán Rừng ngẫu nhiên (Random Forest Classifier)

Rừng ngẫu nhiên là thuật toán học kết hợp nhóm (Ensemble Learning) theo phương pháp **Bagging (Bootstrap Aggregating)** do *Leo Breiman* đề xuất. Thuật toán xây dựng một quần thể gồm B cây quyết định độc lập $\{T_1, T_2, \dots, T_B\}$.

Cơ sở toán học của việc giảm phương sai (Variance Reduction)

Giả sử mỗi cây quyết định đơn lẻ có phương sai là σ^2 và hệ số tương quan giữa hai cây bất kỳ là ρ . Khi lấy trung bình dự đoán của B cây độc lập, phương sai của tổ hợp Rừng ngẫu nhiên được tính bằng:

$$\text{Var}\left(\frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x})\right) = \rho \sigma^2 + \frac{1 - \rho}{B} \sigma^2$$

Khi số lượng cây $B \rightarrow \infty$, số hạng thứ hai $\frac{1 - \rho}{B} \sigma^2 \rightarrow 0$, phương sai tổng thể chỉ còn bị giới hạn bởi $\rho \sigma^2$. Để làm giảm phương sai xuống mức thấp nhất, Random Forest áp dụng hai cơ chế tạo tính ngẫu nhiên:

- Lấy mẫu Bootstrap (Bootstrap Sampling):** Mỗi cây T_b được huấn luyện trên một tập dữ liệu con kích thước N được rút ngẫu nhiên có hoàn lại từ tập dữ liệu gốc. Xác suất một mẫu không được chọn vào cây (Out-of-Bag - OOB) xấp xỉ bằng: $\lim_{N \rightarrow \infty} \left(1 - \frac{1}{N}\right)^N = e^{-1} \approx 36.8\%$ Tập OOB này đóng vai trò như tập kiểm thử chéo nội tại để ước lượng sai số không chệch.

2. Không gian con ngẫu nhiên (Random Subspace Method): Tại mỗi nút phân chia, thuật toán không xem xét toàn bộ d đặc trưng mà chỉ chọn ngẫu nhiên một tập con $m = \sqrt{d}$ hoặc $m = \log_2(d)$ đặc trưng. Điều này làm giảm mạnh độ tương quan ρ giữa các cây, từ đó triệt tiêu phương sai của mô hình.

Dự đoán xác suất cuối cùng là trung bình xác suất của toàn bộ các cây:

$$\hat{P}(y = 1 \mid \mathbf{x}) = \frac{1}{B} \sum_{b=1}^B P_b(y = 1 \mid \mathbf{x})$$

4.5. Thuật toán Gradient Boosting Classifier (Mô hình Champion)

Khác biệt căn bản với Random Forest (các cây hoạt động song song độc lập), **Gradient Boosting (GBDT)** do *Jerome Friedman (2001)* phát minh hoạt động theo nguyên lý Boosting tuần tự (Sequential Ensemble): Mỗi cây quyết định kế tiếp được xây dựng để sửa chữa những sai lầm còn sót lại của tổ hợp các cây phía trước.

Toán học tối ưu hóa trên không gian hàm (Functional Gradient Descent)

Xét bài toán cực tiểu hóa hàm mất mát tổng thể $\mathcal{L}(y, F(\mathbf{x}))$:

$$F^*(\mathbf{x}) = \arg\min_F \mathbb{E}_{(y, \mathbf{x})} [\mathcal{L}(y, F(\mathbf{x}))]$$

Trong bài toán phân loại nhị phân, hàm mất mát là **Log-Loss (Binary Deviance)**. Giả sử $F(\mathbf{x}) = \ln\left(\frac{p}{1-p}\right)$ là hàm log-odds (logit):

$$\mathcal{L}(y, F(\mathbf{x})) = \ln(1 + e^{F(\mathbf{x})}) - y \cdot F(\mathbf{x})$$

Quy trình lặp của thuật toán Gradient Boosting:

1. Khởi tạo mô hình cơ sở $F_0(\mathbf{x})$: Là một giá trị hằng số tối ưu hóa hàm mất mát trên toàn bộ dữ liệu: $F_0(\mathbf{x}) = \arg\min_{\gamma} \sum_{i=1}^N \mathcal{L}(y_i, \gamma) = \ln\left(\frac{\sum y_i}{N - \sum y_i}\right) = \ln\left(\frac{\bar{y}}{1 - \bar{y}}\right)$

2. Với mỗi vòng lặp $m = 1, 2, \dots, M$ (với $M = 550$ cây):

- **Bước a:** Tính toán phần dư giả (Pseudo-Residuals) hay đạo hàm riêng âm của hàm mất mát đối với mô hình hiện tại: $r_{im} = -\left[\frac{\partial \mathcal{L}(y_i, F(\mathbf{x}_i))}{\partial F(\mathbf{x}_i)}\right]_{F(\mathbf{x}) = F_{m-1}}$

$(\mathbf{x})) = y_i - \sigma(F_{m-1}(\mathbf{x}_i)) = y_i - p_{i, m-1}$ Nhận xét sâu sắc: Phần dư tại mỗi bước chính là hiệu số giữa nhãn thực tế $y_i \in \{0, 1\}$ và xác suất dự đoán hiện tại $p_{i, m-1}$. Mẫu nào bị dự đoán sai nhiều sẽ có $|r_{im}|$ lớn, buộc cây kế tiếp phải tập trung sửa sai cho mẫu đó!

- **Bước b:** Huấn luyện một cây hồi quy (Regression Tree) $h_m(\mathbf{x})$ để khớp với các phần dư r_{im} , tạo ra các vùng lá R_{jm} với $j = 1, \dots, J_m$.
- **Bước c:** Với mỗi vùng lá R_{jm} , tính giá trị đầu ra tối ưu γ_{jm} :

$$\gamma_{jm} = \arg\min_{\gamma} \sum_{\mathbf{x}_i \in R_{jm}} \mathcal{L}(y_i, F_{m-1}(\mathbf{x}_i) + \gamma) = \frac{\sum_{\mathbf{x}_i \in R_{jm}} r_{im}}{\sum_{\mathbf{x}_i \in R_{jm}} p_{i, m-1} (1 - p_{i, m-1})}$$
- **Bước d:** Cập nhật hàm dự đoán tổng thể có kết hợp tham số co rút (Shrinkage / Learning Rate) $\nu \in (0, 1]$:

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \nu \sum_{j=1}^{J_m} \gamma_{jm} \mathbb{I}(\mathbf{x} \in R_{jm})$$

3. Dự đoán xác suất cuối cùng sau M cây: $\hat{P}(y = 1 \mid \mathbf{x}) = \sigma(F_M(\mathbf{x})) = \frac{1}{1 + e^{-F_M(\mathbf{x})}}$

Bảng tham số tối ưu đạt được qua RandomizedSearchCV ($N_{\text{iter}} = 80$)

Siêu tham số (Hyperparameter)	Giá trị tối ưu	Miền tìm kiếm	Tác động kỹ thuật & Vai trò
<code>n_estimators</code>	550	$[100, 200, 300, 500, 600]$	Số lượng cây Boosting tuần tự. 550 cây đủ lớn để học sâu các chi tiết mà không làm tràn bộ nhớ.
<code>learning_rate</code> (ν)	0.0562	$[0.01, 0.20]$	Tốc độ học (Shrinkage). Giá trị nhỏ giúp mô hình bước đi cẩn trọng trên không gian hàm, chống Overfitting.
<code>max_depth</code>	14	$[3, 4, 5, 6, 7, 10, 14, 16]$	Độ sâu tối đa của mỗi cây. Cho phép mô hình học được các tương tác bậc cao giữa 14 thuộc tính.
<code>subsample</code>	0.95	$[0.6, 0.7, 0.8, 0.9, 1.0]$	Tỷ lệ mẫu ngẫu nhiên cho mỗi cây (Stochastic Gradient Boosting), giúp bổ sung tính ngẫu nhiên làm giảm phương sai.
<code>min_samples_split</code>	3	$[2, 5, 10]$	Số lượng mẫu tối thiểu để tiếp tục phân nhánh tại một nút nội vi.

Siêu tham số (Hyperparameter)	Giá trị tối ưu	Miền tìm kiếm	Tác động kỹ thuật & Vai trò
min_samples_leaf	1	\$(1, 2, 3)\$	Số lượng mẫu tối thiểu tại một nút lá.

CHƯƠNG 5: MÔ TẢ DỮ LIỆU & QUY TRÌNH TIỀN XỬ LÝ CHỐNG RÒ RỈ

5.1. Nguồn gốc dữ liệu & Phân tích khám phá (EDA)

Hệ thống sử dụng bộ dữ liệu chuẩn hóa từ tập dữ liệu thương mại điện tử thực tế *E-Commerce Customer Churn Analysis and Prediction*, sau đó được tiền xử lý và chuyển dịch sang miền giá trị tiền tệ và nhân khẩu học phù hợp với thị trường bán lẻ Việt Nam.

- Tổng số quan sát:** 5.630 bản ghi khách hàng hoàn chỉnh.
- Tập huấn luyện (Training Set - 80%):** 4.504 bản ghi.
- Tập kiểm thử độc lập (Test Set - 20%):** 1.126 bản ghi (được cô lập hoàn toàn).
- Số lượng đặc trưng ban đầu:** 8 thuộc tính RFM+ và nhân khẩu học.
- Số lượng đặc trưng sau biến đổi:** 14 chiều (gồm 10 biến số sau chuẩn hóa và 4 biến nhị phân từ mã hóa One-Hot).

Bảng thống kê mô tả các thuộc tính số học (Descriptive Statistics)

Thuộc tính	Giá trị trung bình (Mean)	Độ lệch chuẩn (Std)	Giá trị nhỏ nhất (Min)	Trung vị (Median - 50%)	Giá trị lớn nhất (Max)
age	39.18 tuổi	9.24	18 tuổi	38 tuổi	70 tuổi
total_purchases	16.22 đơn	9.45	1 đơn	14 đơn	60 đơn
avg_order_value	1.768.420 đ	842.150 đ	150.000 đ	1.520.000 đ	4.500.000 đ
days_since_last_purchase	35.41 ngày	28.62	1 ngày	28 ngày	180 ngày
satisfaction_score	3.07 sao	1.21	1 sao	3 sao	5 sao
purchase_intensity (FE)	0.82 đơn/ngày	1.14	0.008	0.48	15.00

Thuộc tính	Giá trị trung bình (Mean)	Độ lệch chuẩn (Std)	Giá trị nhỏ nhất (Min)	Trung vị (Median - 50%)	Giá trị lớn nhất (Max)
ltv_score (FE)	28.65 triệu đ	24.31	0.15 triệu đ	21.28 triệu đ	270.00 triệu đ
satisfaction_recency (FE)	4.12 điểm	4.85	0.16	2.72	75.00

5.2. Vấn đề mất cân bằng mẫu và giải pháp phân tầng (Stratified Sampling)

Một thách thức kinh điển trong bài toán Churn là **Sự mất cân bằng nhân tự nhiên (Natural Class Imbalance)**: Trong một doanh nghiệp đang hoạt động ổn định, đa số khách hàng sẽ ở lại hoặc phát sinh giao dịch tiếp theo, chỉ một tỷ lệ nhỏ quyết định rời bỏ:

$$N_{\text{total}} = 5.630 \quad \implies \quad \begin{cases} N(y = 1) = 4.672 \\ \quad (\approx 83.0\% \text{ - Khách hàng quay lại}) \\ N(y = 0) = 958 \quad (\approx 17.0\% \text{ - Khách hàng rời bỏ / Churn}) \end{cases}$$

Hiểm họa từ "Nghịch lý độ chính xác" (Accuracy Paradox)

Nếu một mô hình tầm thường (Naive Model) luôn dự đoán \$100\%\$ khách hàng đều quay lại (\$y=1\$), mô hình đó vẫn dễ dàng đạt độ chính xác \$\text{Accuracy} = 83.0\%\$. Tuy nhiên, mô hình này hoàn toàn vô dụng trong thực tế vì bỏ sót toàn bộ \$100\%\$ các khách hàng đang rời bỏ (\$\text{Recall}_{\text{churn}} = 0\$).

Để giải quyết triệt để vấn đề này, hệ thống áp dụng đồng thời hai giải pháp kỹ thuật:

1. Phân chia lấy mẫu phân tầng (Stratified Train/Test Split):

Sử dụng `train_test_split(..., stratify=y)` để đảm bảo cả hai tập Train (4.504 mẫu) và Test (1.126 mẫu) đều giữ tỷ lệ nhân chính xác tuyệt đối là \$83.0\%\$ và \$17.0\%\$, loại bỏ hoàn toàn hiện tượng lệch phân phối.

2. Cân bằng trọng số hàm mất mát (Cost-Sensitive Weighting):

Trong quá trình huấn luyện các mô hình Logistic Regression và Random Forest, hệ thống kích hoạt tùy chọn `class_weight='balanced'`. Thuật toán tự động nhân trọng số phạt nghịch đảo với tần suất xuất hiện của từng lớp: $w_c = \frac{N}{2 \times N_c}$. Theo đó, lớp Churn (\$y=0\$) được gán trọng số phạt $w_0 \approx 2.94$, cao gấp gần 5 lần so với lớp đa số (\$w_1 \approx 0.60\$). Điều này buộc giải thuật phải chú trọng học chính xác các trường hợp rời bỏ.

5.3. Quy trình tiền xử lý dữ liệu chuẩn hóa chống rò rỉ dữ liệu (Anti-Data Leakage Pipeline)

Định nghĩa Data Leakage: Rò rỉ dữ liệu xảy ra khi thông tin từ tập kiểm thử (Test Set) vô tình được đưa vào quá trình huấn luyện của mô hình. Lỗi phổ biến nhất là việc người lập trình áp dụng các hàm như `StandardScaler.fit()` hoặc `SimpleImputer.fit()` trên toàn bộ bảng dữ liệu trước khi thực hiện chia tách Train/Test. Khi đó, giá trị trung bình μ và độ lệch chuẩn σ của tập Test đã "thấm" vào tập Train, khiến mô hình đạt kết quả kiểm thử ảo rất cao nhưng thất bại khi chạy dữ liệu thực tế.

Kiến trúc Anti-Data Leakage của Boomerang Radar AI:

Hàm `prepare_data()` trong `src/data_processing.py` được thiết kế theo quy trình nghiêm ngặt:

- Bước 1: Nạp dữ liệu & Thực hiện Feature Engineering (các phép toán hoàn toàn mang tính độc lập trên từng dòng dữ liệu).
- Bước 2: Gọi `train_test_split()` để cô lập hoàn toàn tập X_{train} và X_{test} .
- Bước 3: Khởi tạo `ColumnTransformer` chứa `StandardScaler` cho 10 cột số và `OneHotEncoder(drop='first')` cho 2 cột danh mục.
- Bước 4: Gọi `preprocessor.fit_transform(X_train)` **DUY NHẤT trên tập Train** để tính toán và lưu giữ vector $(\mu_{\text{train}}, \sigma_{\text{train}})$.
- Bước 5: Áp dụng `preprocessor.transform(X_test)` trên tập Test bằng các tham số đã đồng bộ của tập Train mà không học lại.
- Bước 6: Lưu trữ đối tượng biến đổi ra file `models/preprocessor.joblib` phục vụ cho tầng suy luận (Inference).

Không gian đặc trưng 14 chiều sau khi biến đổi

Sau khi đi qua bộ `ColumnTransformer`, vector đầu vào có chính xác 14 chiều số học:

STT	Tên đặc trưng sau biến đổi	Phép biến đổi toán học	Miền giá trị sau xử lý
1	age	StandardScaler: $(x - \mu) / \sigma$	$\mathbb{R}$ (Mean ≈ 0 , Var ≈ 1)
2	total_purchases	StandardScaler: $(x - \mu) / \sigma$	$\mathbb{R}$

STT	Tên đặc trưng sau biến đổi	Phép biến đổi toán học	Miền giá trị sau xử lý
3	avg_order_value	StandardScaler: $(x - \mu) / \sigma$	$\mathbb{R}$
4	days_since_last_purchase	StandardScaler: $(x - \mu) / \sigma$	$\mathbb{R}$
5	used_voucher	StandardScaler: $(x - \mu) / \sigma$	$\mathbb{R}$
6	satisfaction_score	StandardScaler: $(x - \mu) / \sigma$	$\mathbb{R}$
7	purchase_intensity	StandardScaler: $(x - \mu) / \sigma$	$\mathbb{R}$
8	ltv_score	StandardScaler: $(x - \mu) / \sigma$	$\mathbb{R}$
9	satisfaction_recency	StandardScaler: $(x - \mu) / \sigma$	$\mathbb{R}$
10	voucher_low_value	StandardScaler: $(x - \mu) / \sigma$	$\mathbb{R}$
11	gender_Nữ	OneHotEncoder (drop='first', Nam làm gốc)	\$0\$ hoặc \$1\$
12	membership_level_Đồng	OneHotEncoder (drop='first', Bạc làm gốc)	\$0\$ hoặc \$1\$
13	membership_level_Vàng	OneHotEncoder	\$0\$ hoặc \$1\$
14	membership_level_Kim Cương	OneHotEncoder	\$0\$ hoặc \$1\$

CHƯƠNG 6: CÀI ĐẶT HỆ THỐNG VÀ XÂY DỰNG ỨNG DỤNG

6.1. Môi trường công nghệ và Cấu trúc mã nguồn

Hệ thống được phát triển trên nền tảng ngôn ngữ **Python 3.10** kết hợp với hệ sinh thái các thư viện khoa học dữ liệu hiện đại. Cấu trúc dự án được phân cấp mô-đun hóa rõ ràng, đáp ứng các tiêu chuẩn Clean Code và kiến trúc phần mềm hướng dịch vụ (Service-Oriented Architecture):

```
Boomerang_Radar_AI/
├── app.py # Máy chủ Flask, điều phối HTTP Endpoints & API Routing
├── requirements.txt # Danh mục các gói phụ thuộc (Flask, Scikit-learn, Pandas, Joblib)
├── README.md # Tài liệu hướng dẫn cài đặt môi trường và vận hành hệ thống
├── .gitignore # Bộ lọc tệp tin rác biên dịch (.pyc, cache, virtualenvs)
├── BAO CAO DU AN BOOMERANG RADAR AI.pdf # Bản báo cáo toàn diện 30 trang in ấn chuẩn A4
├── data/
│   └── customer_repurchase_data.csv # Tệp dữ liệu sạch 5.630 bản ghi chuẩn hóa RFM+
├── models/
│   ├── gradient_boosting_model.joblib # Trọng số mô hình Champion (Gradient Boosting 94.23%)
│   ├── random_forest_model.joblib # Trọng số mô hình đối sánh Random Forest (91.56%)
│   ├── decision_tree_model.joblib # Trọng số mô hình đối sánh Decision Tree (74.96%)
│   ├── logistic_regression_model.joblib # Trọng số mô hình Baseline Logistic Regression (68.47%)
│   ├── preprocessor.joblib # Đối tượng ColumnTransformer đã fit tham số
│   ├── feature_names.joblib # Danh mục tên 14 đặc trưng sau mã hóa OneHot
│   ├── raw_feature_cols.joblib # Danh mục 8 cột thuộc tính đầu vào ban đầu
│   └── evaluation_results.json # Tệp kết quả đánh giá thực nghiệm, metrics & Feature Importances
├── src/
│   ├── __init__.py # Khởi tạo gói Python nội bộ
│   └── data_processing.py # Pipeline nạp dữ liệu, FE, chống data leakage & lưu
├── preprocessor
│   └── train.py # Kịch bản huấn luyện, RandomizedSearchCV, 5-Fold CV & xuất
├── artifacts
│   └── predict.py # Bộ máy suy luận đơn lẻ, batch inference & logic sinh khuyến
nghị
├── templates/
│   └── index.html # Giao diện Web Dashboard Bootstrap 5 tích hợp 4 phân hệ
```

6.2. Cài đặt chi tiết các Module lõi trong hệ thống

Module 1: Tiền xử lý dữ liệu và Kỹ thuật đặc trưng (src/data_processing.py)

Module này đảm nhận hai nhiệm vụ sống còn: Kỹ thuật đặc trưng tương tác và Tiền xử lý chống rò rỉ dữ liệu.

- **Hàm `engineer_features(df)`:** Áp dụng các phép tính véc-tơ hóa bằng Pandas/NumPy để sinh đồng thời 4 cột tương tác mới:

```
df['purchase_intensity'] = df['total_purchases'] / (df['days_since_last_purchase'] + 1)
df['ltv_score'] = df['total_purchases'] * df['avg_order_value'] / 1_000_000
df['satisfaction_recency'] = df['satisfaction_score'] / (df['days_since_last_purchase'] + 1) * 30
df['voucher_low_value'] = ((df['used_voucher'] == 1) & (df['avg_order_value'] <= 300_000)).astype(int)
```

- **Hàm `prepare_data(test_size=0.2, random_state=42)`:** Thiết lập `ColumnTransformer` chứa `StandardScaler` cho 10 biến số học và `OneHotEncoder(drop='first', sparse_output=False, handle_unknown='ignore')` cho 2 biến danh mục. Gọi `fit_transform` trên `X_train` và chỉ `transform` trên `X_test`. Lưu giữ bộ biến đổi ra `models/preprocessor.joblib`.

Module 2: Huấn luyện và Tối ưu hóa mô hình (`src/train.py`)

Chịu trách nhiệm thực thi pipeline huấn luyện tự động với tiêu chí dùng nghiệm khắt khe:

- **Ngưỡng mục tiêu đánh giá:** Thiết lập các hằng số kiểm định: $\$F_1 \geq 0.92$, $\text{Accuracy} \geq 0.90$, $\text{ROC-AUC} \geq 0.90$
- **Chiến lược kiểm định chéo phân tầng:** Khởi tạo `StratifiedKFold(n_splits=5, shuffle=True, random_state=42)` để duy trì tỷ lệ nhãn Churn 17% đồng đều trong cả 5 lần lặp.
- **Tối ưu hóa siêu tham số:** Sử dụng `RandomizedSearchCV` với số vòng lặp $N_{\text{iter}} = 60$ cho Random Forest và $N_{\text{iter}} = 80$ cho Gradient Boosting. Tự động tính toán ma trận nhầm lẫn, trích xuất độ quan trọng của đặc trưng (Feature Importance), ghi nhận mô hình tốt nhất vào khóa `_best_model` và xuất báo cáo hoàn chỉnh ra file `models/evaluation_results.json`.

Module 3: Bộ máy suy luận thời gian thực và sinh khuyến nghị (`src/predict.py`)

Module trung tâm phục vụ cho ứng dụng thực tế:

- **Hàm `load_inference_artifacts(model_name)`:** Áp dụng kỹ thuật nạp lười (Lazy Loading) để lưu bộ nhớ. Nạp đúng file nhị phân `.joblib` của mô hình được yêu cầu và bộ biến đổi `preprocessor.joblib`.
- **Hàm `generate_synthesis_analysis(customer_dict)`:** Phân tích 5 khía cạnh hành vi (tần suất mua, quy mô đơn hàng, khoảng cách ngày mua, trải nghiệm dịch vụ và hành vi sẵn khuyến mãi) để ghép nối thành câu văn ngữ cảnh tự nhiên tiếng Việt mượt mà, giúp chuyên viên bán hàng nắm bắt nhanh tâm lý khách hàng mà không cần phân tích từng con số thô.
- **Hàm `predict_single_customer(...)`:** Thực hiện toàn bộ quy trình: Ánh xạ 4 biến tương tác $\rightarrow$ Transform qua `preprocessor` $\rightarrow$ Tính $P(y=1) = \text{predict_proba}()[0, 1]$ $\rightarrow$ So sánh với Threshold $\rightarrow$ Gán mức rủi ro $\rightarrow$ Gán kịch bản hành động Marketing tương ứng $\rightarrow$ Đóng gói Dictionary kết quả.

- Hàm `predict_batch_df(df_input, threshold=0.50)`: Tối ưu hóa vector hóa để dự đoán đồng thời hàng nghìn dòng dữ liệu từ DataFrame, gán thêm 3 cột: `xac_suat_quay_lai_%`, `du_doan_quay_lai`, và `trang_thai` phục vụ xuất file CSV.

6.3. Xây dựng dịch vụ Web REST API (app.py)

Máy chủ Flask cung cấp các REST API Endpoints được chuẩn hóa theo chuẩn trao đổi dữ liệu JSON:

HTTP Method	Tuyến đường (Endpoint)	Dữ liệu đầu vào (Payload)	Chức năng nghiệp vụ & Phản hồi (Response)
GET	/	None	Render giao diện trang chủ Web Dashboard Bootstrap 5 (templates/index.html).
GET	/api/stats	None	Trả về số lượng khách hàng, tỷ lệ quay lại, tỷ lệ rời bỏ, AOV toàn sản và 15 dòng dữ liệu xem trước.
GET	/api/models	None	Trả về toàn bộ nội dung file <code>evaluation_results.json</code> phục vụ vẽ bảng benchmark và biểu đồ.
POST	/api/predict	JSON chứa 8 chỉ số của 1 khách hàng + <code>threshold</code> + <code>model_name</code>	Thực hiện suy luận thời gian thực, trả về xác suất, phân tầng rủi ro, câu phân tích và lời khuyên nghiệp vụ.
POST	/api/predict-batch	Multipart File Upload (CSV) hoặc lấy 30 dòng mẫu	Dự đoán hàng loạt, trả về danh sách các bản ghi đã gán nhãn và xác suất phục vụ tải file kết quả.

6.4. Thiết kế giao diện Dashboard tương tác (templates/index.html)

Giao diện Web Dashboard được thiết kế theo phong cách hiện đại với 4 phân hệ tương tác riêng biệt:

- **Tab 1: Overview (Tổng quan dữ liệu):** Hiển thị 4 thẻ KPI vĩ mô (Tổng khách hàng, Tỷ lệ quay lại 83%, Tỷ lệ rời bỏ 17%, AOV trung bình) và bảng hiển thị 15 dòng dữ liệu mẫu trực quan.

- **Tab 2: Predictor (Radar dự đoán cá nhân):** Cung cấp form nhập liệu trực quan cho 8 chỉ số; cho phép người dùng tùy chỉnh ngưỡng phân loại (Threshold Slider) từ \$0.1\$ đến \$0.9\$; thanh tiến trình radar hiển thị xác suất quay lại kèm mã màu trạng thái (Xanh lá: An toàn, Vàng: Cảnh báo, Đỏ: Rủi ro Churn cực cao) và hộp khuyến nghị hành động Marketing.
- **Tab 3: Benchmark (ĐỐI CHUẨN MÔ HÌNH):** Bảng so sánh 4 mô hình theo 5 chỉ số; bảng ma trận nhầm lẫn (Confusion Matrix) trực quan; và biểu đồ cột nằm ngang hiển thị mức độ quan trọng của 14 đặc trưng được vẽ tự động bằng thư viện **Chart.js**.
- **Tab 4: Batch Processing (Xử lý hàng loạt):** Khu vực kéo thả tệp tin CSV, hiển thị bảng kết quả phân loại phân trang và nút chức năng **Export CSV** tải về máy.

CHƯƠNG 7: ĐÁNH GIÁ KẾT QUẢ THỰC NGHIỆM

7.1. Hệ thống chỉ số đánh giá thực nghiệm (Evaluation Metrics Framework)

Để đánh giá khách quan và toàn diện năng lực của các mô hình học máy trên tập kiểm thử độc lập (Held-out Test Set gồm 1.126 khách hàng), hệ thống sử dụng một khung chỉ số đo lường chuẩn mực theo tiêu chuẩn quốc tế:

1. Độ chính xác tổng thể (Accuracy)

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Đo lường tỷ lệ các dự đoán đúng (cả khách quay lại và khách rời bỏ) trên tổng số mẫu kiểm thử.

2. Độ chuẩn xác (Precision)

$$\text{Precision} = \frac{TP}{TP + FP}$$

Trong số các khách hàng mà mô hình dự đoán là "*Sẽ quay lại*", có bao nhiêu phần trăm thực sự quay lại mua sắm. Precision cao đồng nghĩa với việc hạn chế việc đưa ra dự báo lạc quan sai lầm.

3. Độ nhạy / Thu hồi (Recall / Sensitivity)

$$\text{Recall} = \frac{TP}{TP + FN}$$

Trong toàn bộ số khách hàng thực tế quay lại, mô hình đã "bắt trúng" được bao nhiêu phần trăm. Recall càng cao nghĩa là số lượng khách hàng trung thành bị bỏ sót (FN) càng nhỏ.

4. Điểm F1 (F1-Score - Trung bình điều hòa)

$$F_1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN}$$

Là thước đo quan trọng nhất đối với bài toán mất cân bằng nhãn, đảm bảo mô hình không thể "gian lận" bằng cách hy sinh Precision để đổi lấy Recall hoặc ngược lại.

5. Diện tích dưới đường cong ROC (Area Under the ROC Curve - ROC-AUC)

$$\text{ROC-AUC} = \int_0^1 \text{TPR}(\text{FPR}^{-1}(t)) \, dt$$

Đo lường năng lực phân biệt (Discriminative Power) tổng quát của mô hình trên mọi ngưỡng quyết định $\theta \in [0, 1]$. Giá trị $\text{ROC-AUC} \in [0.5, 1.0]$, giá trị càng tiệm cận 1.0 thể hiện mô hình xếp hạng xác suất cực kỳ tin cậy.

7.2. Bảng so sánh tổng hợp hiệu năng giữa các mô hình

Bảng đối chuẩn hiệu năng thực nghiệm trên tập kiểm thử độc lập gồm **1.126 khách hàng** hoàn toàn chưa từng xuất hiện trong quá trình huấn luyện hay tối ưu siêu tham số:

STT	Mô hình thuật toán	Accuracy	Precision	Recall	F1-Score	ROC-AUC	Trạng thái mục tiêu
1	Logistic Regression	68.47%	0.9395	0.6635	0.7777	0.7906	Chưa đạt (Baseline)
2	Decision Tree	74.96%	0.9348	0.7511	0.8329	0.8089	Khá tốt
3	Random Forest	91.56%	0.9367	0.9637	0.9500	0.9575	Đạt chỉ tiêu
4	Gradient Boosting	94.23%	0.9570	0.9744	0.9656	0.9695	★ VÔ ĐỊCH (Champion)

Phân tích khoa học lý giải sự vượt trội của Gradient Boosting:

1. **So với Logistic Regression (+25.76% Accuracy):** Không gian ranh giới quyết định giữa khách quay lại và rời bỏ có tính phi tuyến cao. Mô hình tuyến tính hoàn toàn bất lực trong việc nắm bắt các quy tắc điều kiện lồng nhau.

2. **So với Decision Tree (+19.27% Accuracy):** Cây quyết định đơn lẻ có phương sai rất lớn và dễ bị mắc kẹt tại các cực tiểu cục bộ.
3. **So với Random Forest (+2.67% Accuracy, +1.56% F1):** Random Forest chỉ giảm phương sai nhờ việc lấy trung bình độc lập các cây. Ngược lại, Gradient Boosting sử dụng kỹ thuật tối ưu hóa phần dư theo hướng Gradient Descent, giúp mô hình tập trung học tỉ mỉ từng trường hợp biên giới khó phân loại, đạt được độ cân bằng hoàn hảo giữa phương sai và độ chệch (Bias-Variance Tradeoff).

7.3. Phân tích Ma trận nhầm lẫn (Confusion Matrix Breakdown) và Tác động kinh tế

Ma trận nhầm lẫn của mô hình Gradient Boosting trên 1.126 khách hàng kiểm thử độc lập:

Thực tế (Ground Truth)	Dự đoán của mô hình AI (Predicted)	
	Dự đoán Churn (\$y=0\$)	Dự đoán Quay lại (\$y=1\$)
Khách Churn thực tế (\$y=0\$)	TN = 149	FP = 41
Khách Quay lại thực tế (\$y=1\$)	FN = 24	TP = 912

Phân tích tác động kinh tế học của hai loại sai lầm

- Sai lầm loại 2 - Âm tính giả (False Negative - FN = 24):**
Khách hàng thực tế vẫn sẽ quay lại mua sắm nhưng hệ thống dự đoán nhầm thành có nguy cơ rời bỏ. Trong trường hợp này, doanh nghiệp sẽ gửi nhầm mã khuyến mãi hoặc voucher tri ân giảm 15% cho khách hàng này. Thiệt hại kinh tế chỉ là một phần nhỏ biên lợi nhuận của đơn hàng tiếp theo. *Mô hình đã không chế số ca FN xuống mức cực thấp (chỉ 24 trên 1.126 khách, tương đương 2.13%), bảo đảm doanh nghiệp không bị thất thoát lợi nhuận do phát voucher tràn lan.*
- Sai lầm loại 1 - Dương tính giả (False Positive - FP = 41):**
Khách hàng thực tế đã có ý định rời bỏ nhưng hệ thống chủ quan dự đoán họ vẫn sẽ quay lại. Doanh nghiệp sẽ không tiến hành can thiệp chăm sóc và hậu quả là mất vĩnh viễn khách hàng này vào tay đối thủ. Với số lượng 41 ca trên 190 khách Churn thực tế, tỷ lệ phát hiện sớm Churn của mô hình đạt: $\text{Specificity} = \frac{TN}{TN + FP} = \frac{149}{149 + 41}$

+ 41} \approx 78.42\%\$\$\$ Đây là một tỷ lệ phát hiện rất ấn tượng đối với bài toán mất cân bằng nhãn cao trong thực tế thương mại điện tử.

7.4. Xếp hạng và Đánh giá mức độ quan trọng của đặc trưng (Feature Importance)

Trong thuật toán Gradient Boosting, độ quan trọng của một đặc trưng \$j\$ được tính toán dựa trên mức độ suy giảm trung bình của hàm mất mát (MDI - Mean Decrease in Impurity) qua toàn bộ các điểm phân tách có sử dụng đặc trưng đó trong tất cả \$M = 550\$ cây:

Xếp hạng	Tên đặc trưng	Tỷ lệ đóng góp (%)	Phân loại nguồn gốc	Ý nghĩa và Phân tích tương quan
1	avg_order_value	23.59%	Đặc trưng gốc	Giá trị đơn trung bình là chỉ báo tài chính trực tiếp phản ánh mức độ cam kết của khách.
2	age	23.08%	Đặc trưng gốc	Độ tuổi tương quan chặt chẽ với thói quen mua sắm và độ trung thành nhãn hàng.
3	ltv_score	20.61%	Kỹ thuật đặc trưng (FE)	Tổng đóng góp doanh thu tích lũy khẳng định nhóm khách hàng VIP luôn có xác suất quay lại cao nhất.
4	satisfaction_recency	9.90%	Kỹ thuật đặc trưng (FE)	Sự suy giảm điểm hài lòng theo thời gian cảnh báo chính xác thời điểm khách hàng chuẩn bị chuyển đổi.
5	purchase_intensity	6.57%	Kỹ thuật đặc trưng (FE)	Khách hàng có nhịp độ mua hàng dày đặc luôn có quán tính tiếp tục phát sinh giao dịch.
6	days_since_last_purchase	3.73%	Đặc trưng gốc	Khoảng cách ngày mua càng lớn, rủi ro rời bỏ càng tăng cao.
7	satisfaction_score	3.58%	Đặc trưng gốc	Điểm số đánh giá trải nghiệm thực tế.

Xếp hạng	Tên đặc trưng	Tỷ lệ đóng góp (%)	Phân loại nguồn gốc	Ý nghĩa và Phân tích tương quan
8	gender_Nữ	3.23%	Mã hóa danh mục	Khách hàng nữ có xu hướng phát sinh các giao dịch lặp lại thường xuyên hơn trong ngành thời trang/tiêu dùng.
9	membership_level_Đồng	2.02%	Mã hóa danh mục	Hội viên hạng Đồng có mức độ gắn kết yếu nhất, tỷ lệ Churn cao nhất.
10	used_voucher	1.46%	Đặc trưng gốc	Thói quen sử dụng mã giảm giá để kích thích mua sắm.
11 - 14	Các biến còn lại	2.23%	Mã hóa danh mục & FE	Hạng Vàng, Kim Cương, Tổng đơn và nhóm sản voucher giá trị thấp.

Tổng kết then chốt: Tổng tỷ trọng đóng góp của 4 biến sinh ra từ Feature Engineering (ltv_score, satisfaction_recency, purchase_intensity, voucher_low_value) chiếm tới **37.08%** tổng năng lực phân loại của mô hình. Điều này chứng minh luận điểm khoa học: *Kỹ thuật đặc trưng tương tác kết hợp tri thức kinh doanh sâu sắc chính là nhân tố cốt lõi giúp hệ thống AI bứt phá từ mức khá (91%) lên mức xuất sắc (94.23%).*

CHƯƠNG 8: HƯỚNG PHÁT TRIỂN & KẾT LUẬN

8.1. Ứng dụng Trí tuệ Nhân tạo có thể giải thích (Explainable AI - XAI)

Trong giai đoạn phát triển tiếp theo, việc chuyển đổi từ mô hình "hộp đen" (Black-Box Model) sang mô hình có khả năng minh bạch hóa quyết định (Transparent & Explainable AI) là mục tiêu trọng tâm nhằm gia tăng mức độ tin tưởng của người sử dụng và ban lãnh đạo doanh nghiệp.

Cơ sở toán học của Giá trị Shapley (Shapley Additive exPlanations - SHAP)

Hệ thống dự kiến tích hợp thuật toán **TreeSHAP** (Lundberg & Lee, 2017) dựa trên lý thuyết trò chơi hợp tác (Cooperative Game Theory) của nhà kinh tế học đoạt giải Nobel *Lloyd Shapley*

(1953). Giá trị Shapley ϕ_i phân bổ mức độ đóng góp công bằng của thuộc tính thứ i vào độ lệch giữa xác suất dự đoán $f(\mathbf{x})$ và xác suất kỳ vọng nền $\mathbb{E}[f(X)]$:

$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|! (|N| - |S| - 1)!}{|N|!} [v(S \cup \{i\}) - v(S)]$$

Trong đó:

- N là tập hợp toàn bộ d thuộc tính đầu vào của khách hàng.
- S là một liên minh tập con các thuộc tính không chứa thuộc tính i .
- $v(S)$ là giá trị kỳ vọng dự đoán của mô hình khi chỉ có thông tin từ tập con S .
- $\frac{|S|! (|N| - |S| - 1)!}{|N|!}$ là xác suất xuất hiện của tập con S theo phân phối hoán vị ngẫu nhiên.

Ứng dụng trên Dashboard: Khi một khách hàng bị cảnh báo rủi ro rời bỏ ở cấp độ "Rất Cao", hệ thống sẽ tự động vẽ một **Biểu đồ thác nước (Waterfall Plot)**. Biểu đồ này chỉ rõ thuộc tính nào đang kéo tụt điểm số (ví dụ: `days_since_last_purchase = 120` đóng góp $\phi = -0.35$, `satisfaction_score = 1` đóng góp $\phi = -0.22$), giúp nhân viên CSKH biết chính xác "nỗi đau" của khách hàng để có cách tiếp cận phù hợp nhất.

8.2. Mở rộng kiến trúc thuật toán chuyên biệt cho dữ liệu bảng

Khi quy mô dữ liệu doanh nghiệp mở rộng từ hàng nghìn lên hàng triệu bản ghi, hệ thống sẽ mở rộng nghiên cứu sang 3 kiến trúc tiên tiến:

1. LightGBM (Light Gradient Boosting Machine - Microsoft):

Sử dụng cơ chế gom cụm đặc trưng theo biểu đồ tần suất (Histogram-based) và chiến lược phân nhánh theo lá sâu nhất (Leaf-wise split with depth limit) thay vì theo tầng (Level-wise). Giúp tăng tốc độ huấn luyện lên từ 5 đến 10 lần và giảm 70% mức sử dụng bộ nhớ RAM.

2. CatBoost (Yandex):

Thuật toán GBDT tối ưu hàng đầu thế giới cho các thuộc tính phân loại (Categorical Features) nhờ kỹ thuật Ordered Target Statistics và Oblivious Decision Trees, giúp xử lý biến danh mục (như danh mục sản phẩm, kênh tiếp thị) mà không làm bùng nổ chiều dữ liệu (Curse of Dimensionality).

3. Mạng học sâu TabNet (Google Cloud AI):

Kiến trúc mạng nơ-ron sâu dành riêng cho dữ liệu bảng sử dụng cơ chế chú ý tuần tự

(Sequential Attention Mechanism) tại mỗi bước quyết định để chọn lọc đặc trưng có thể giải thích nội tại mà không cần đến các phương pháp hậu kiểm như SHAP.

8.3. Thiết kế hệ thống MLOps và Tự động hóa tiếp thị đa kênh (Omnichannel Automation)

1. Kiến trúc MLOps giám sát độ trôi dữ liệu (Data Drift & Concept Drift)

Trong thương mại điện tử, hành vi mua sắm của người tiêu dùng liên tục biến động theo mùa vụ (ví dụ: Black Friday, Tết Nguyên Đán). Một mô hình huấn luyện vào mùa hè có thể suy giảm độ chính xác vào mùa đông do có sự trôi dạt phân phối dữ liệu (Data Drift).

Hệ thống đề xuất tích hợp công cụ kiểm định thống kê:

- **Chỉ số ổn định quần thể (Population Stability Index - PSI):**
$$\text{PSI} = \sum_{k=1}^K \left| \frac{\text{Actual}_k - \text{Expected}_k}{\text{Expected}_k} \right| \times \ln \left(\frac{\text{Actual}_k}{\text{Expected}_k} \right)$$
 Nếu $\text{PSI} > 0.25$, hệ thống tự động kích hoạt Webhook cảnh báo dữ liệu đã trôi dạt nghiêm trọng và gọi pipeline `src/train.py` để tự động huấn luyện lại (Auto-Retraining) trên dữ liệu 30 ngày gần nhất.
- **Container hóa & CI/CD:** Đóng gói mã nguồn và môi trường vào Docker Image, triển khai qua GitHub Actions lên hạ tầng Kubernetes (KubeFlow hoặc AWS EKS).

2. Tự động hóa tiếp thị đa kênh (Omnichannel Retention Automation)

Kết nối hệ thống Boomerang Radar AI với các nền tảng CRM và công liên lạc khách hàng (Customer Data Platform - CDP):

- **Kết nối Webhook CRM:** Đồng bộ dữ liệu 2 chiều với HubSpot, Salesforce và Lark Suite.
- **Tự động gửi Zalo ZNS / SMS Brandname:** Ngay khi một khách hàng phát sinh nguy cơ Churn $\geq 80\%$, hệ thống tự động bắn một tin nhắn chăm sóc cá nhân hóa kèm mã giảm giá độc quyền 25% vào tài khoản Zalo của khách hàng.
- **Tự động tạo Task CSKH:** Đối với các khách hàng VIP (hạng Kim Cương hoặc có $\$LTV > 50\$$ triệu đồng), hệ thống tự động tạo một công việc ưu tiên cao trên bảng điều khiển của Trưởng phòng CSKH để thực hiện cuộc gọi thăm hỏi trực tiếp trong vòng 2 giờ làm việc.

8.4. Kết luận toàn diện đề tài

Dự án Boomerang Radar AI đã hoàn thành xuất sắc toàn bộ các mục tiêu nghiên cứu và phát triển được đặt ra:

1. Xây dựng thành công cơ sở lý thuyết toán học vững chắc kết hợp kinh tế học hành vi và phân tích RFM+ mở rộng.
2. Đề xuất và chứng minh tính hiệu quả vượt trội của 4 đặc trưng tương tác phi tuyến, đóng góp tới **37.08%** năng lực dự đoán của toàn bộ hệ thống.
3. Thiết lập pipeline tiền xử lý dữ liệu chuẩn mực, tuân thủ nguyên tắc chống rò rỉ dữ liệu (Anti-Data Leakage) tuyệt đối.
4. Huấn luyện và đối chuẩn thành công 4 thuật toán học máy, trong đó mô hình **Gradient Boosting Classifier** đã xuất sắc vượt qua các tiêu chuẩn kiểm thử khắt khe, đạt độ chính xác **94.23%**, $F_1\text{-score}$ đạt **96.56%** và chỉ số ROC-AUC đạt **96.95%**.
5. Đóng gói và vận hành hoàn chỉnh ứng dụng Web Dashboard đa năng với giao diện trực quan, REST API độ trễ cực thấp ($< 50\text{ms}$) cùng các kịch bản hành động thông minh tạo nên "hiệu ứng Boomerang" giữ chân khách hàng bền vững.

TÀI LIỆU THAM KHẢO (REFERENCES)

1. Friedman, J. H. (2001). *Greedy function approximation: a gradient boosting machine*. Annals of statistics, 1189-1232.
2. Breiman, L. (2001). *Random forests*. Machine learning, 45(1), 5-32.
3. Reichheld, F. F., & Sasser, W. E. (1990). *Zero defections: Quality comes to services*. Harvard Business Review, 68(5), 105-111.
4. Lundberg, S. M., & Lee, S. I. (2017). *A unified approach to interpreting model predictions*. Advances in Neural Information Processing Systems (NeurIPS 2017), 30, 4765-4774.
5. Fader, P. S., Hardie, B. G., & Lee, K. L. (2005). *"Counting your customers" the easy way: An alternative to the Pareto/NBD model*. Marketing Science, 24(2), 275-284.
6. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011). *Scikit-learn: Machine learning in Python*. Journal of machine learning research, 12(Oct), 2825-2830.
7. Chen, T., & Guestrin, C. (2016). *XGBoost: A scalable tree boosting system*. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785-794.
8. Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). *CatBoost: unbiased boosting with categorical features*. Advances in Neural Information Processing Systems (NeurIPS 2018), 31.
9. Arik, S. Ö., & Pfister, T. (2021). *TabNet: Attentive interpretable tabular learning*. Proceedings of the AAAI Conference on Artificial Intelligence, 35(8), 6679-6687.
10. Hughes, A. M. (2005). *Strategic database marketing: The masterplan for starting and managing a profitable, customer-based marketing program*. McGraw-Hill Companies.